

Санкт-Петербургский политехнический университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Научно-исследовательская работа на тему
«Автоматическое фенотипирование на основе обработки изображений и
машинного обучения.
Исследование с использованием облаков точек»

Выполнил

студент гр. 5040102/10201

Долгий В. С.

/_____/

Руководитель

должность

Козлов К. Н.

/_____/

Оценка: _____

«19» марта 2022 г.

Санкт-Петербург

2022

Оглавление

Введение	3
1. Теоретические основы автоматического фенотипирования	4
1.1 Подход к регистрации облака точек растения	4
1.2 Извлечение структуры скелета вместе с семантикой	5
1.3 Оценка соответствий скелета	8
1.4 Вычисление параметров деформации скелета	12
1.5 Деформация облака точек	15
1.6 Итерационная нежесткая процедура регистрации	16
1.7 Облака точек интерполяции растений	16
1.8 Вычисление фенотипических признаков	17
1.9 Описание набора данных	18
1.10 Семантическая классификация облаков точек растений	19
1.11 4D регистрация облаков точек растений	21
1.12 Временное отслеживание фенотипических признаков	25
1.13 Временная интерполяция облаков точек растений	26
2. Проверка работоспособности программной реализации метода	28
Заключение	33
Список использованных источников	34
Приложение	36

Введение

Растениеводство и сельское хозяйство является важной частью в жизни человечества. С помощью этих отраслей добывается пища для поддержания жизнедеятельности организма людей и животных.

Актуальность данной темы крайне высока и будет таковой еще долгое время, так как проблема голода большого количества населения планеты в экономически бедных странах является все еще неполностью разрешимой.

Для получения максимально-эффективного дохода в этих сферах используется мониторинг растений. Он нужен для анализа урожайности и стресса растений. Измерение отдельных растений вручную во время их развития и роста это трудоемкая задача, использующая методы, которые наносят вред растению.

Новые измерительные технологии для измерения и отслеживание фенотипических признаков, использующие лазерные сканеры и RGB-D камеры открывают возможности для автоматического измерения производительности растений.

Целью работы является изучение метода автоматического фенотипирования растений на базе алгоритма пространственно-временной регистрации облаков точек на примере литературных данных по кукурузе и томату.

Задачами НИР будут:

1. Ознакомление с предложенным подходом, математической постановкой задачи на всех этапах самого метода и методом получения эффективных результатов.
2. Проверка применимости и качества результатов подхода на примере входных литературных данных томата и кукурузы.

1. Теоретические основы автоматического фенотипирования

1.1 Подход к регистрации облака точек растения

Подход основан на временных рядах трехмерных облаков точек растений. Процедура регистрации начинается с извлечения скелета вместе с семантикой уровня органа для каждого облака точек. Скелеты представляют собой неориентированные ациклические графы, которые представляют топологию или внутреннюю структуру растения. Каждый узел содержит координаты x, y, z своего положения, матрицу аффинного преобразования 4×4 T для описания локального преобразования и метки семантического класса в качестве атрибутов. Скелеты извлекаются из данных облака точек и часто являются несовершенными. Этот факт учитывается при процедуре регистрации и работа идёт непосредственно с упорядоченными облаками точек и не требуем сетчатой структуры или других сигналов, таких как нормали, предоставляющие внутреннюю и внешнюю информацию о поверхности. Каркасные структуры позволяют вычислять ассоциации данных между разделенными во времени 3D-сканированиями и использовать эти соответствия для выполнения итеративной процедуры, которая регистрирует сканирование растений, полученное в разное время. Наконец, зарегистрированные скелеты могут быть использованы для деформации всего облака точек, например, облака точек с момента времени t_1 деформируется до момента времени t_2 .

Алгоритм 1. Управляемая скелетом итеративная нежесткая процедура регистрации:

1. ρ_1, ρ_2 — облако входных точек,
2. $C_{12}^{t-1}, C_{12}^t = \emptyset$ — инициализация,
3. θ_1 — сегментация ρ_1 ,
4. θ_2 — сегментация ρ_2 ,

5. S_1 – вычислительный скелет (ρ_1, θ_1) ,
6. S_2 – вычислительный скелет (ρ_2, θ_2) ,
7. До тех пор пока $\left(\frac{C_{12}^t}{C_{12}^{t-1}}\right) \cup \left(\frac{C_{12}^{t-1}}{C_{12}^t}\right) = \emptyset$ требуется повторять предыдущие этапы для получения одинаковых совпадений,
8. $C_{12}^{t-1} = C_{12}^t$,
9. C_{12}^t – вычисление совпадений (S_1, S_2) ,
10. τ_{12} – вычисление деформаций (S_1, S_2, C_{12}^t) ,
11. P_1 – нанесение деформации (ρ_1, τ_{12}) .

1.2 Извлечение структуры скелета вместе с семантикой

Первым шагом подхода является извлечение структуры скелета S установки из облака входных точек p . Для достижения такой цели сначала выполняется этап сегментации, направленный на группировку точек, принадлежащих одному и тому же органу растения, а именно одному экземпляру листа или стебля. Для этого начнем классификацию каждой точки облака точек p как точку, которая относится либо к категории стеблей, либо к категории листьев, используя стандартный машинный классификатор опорных векторов вместе с гистограммами быстрых точечных объектов как вектор признаков. Метод гистограмм быстрых точечных объектов вычисляет гистограмму направлений вокруг точки, используя информацию о окрестности, тем самым фиксируя локальные свойства поверхности в компактной форме. Используя эти векторы признаков в качестве входных данных, машина опорных векторов может классифицировать каждую точку облака точек растения на точки стебля и листа. Модель машины опорных векторов обучается с помощью библиотеки `scikit-learn` контролируемым образом, предоставляя метки для двух случайно выбранных сканирований временной последовательности в качестве обучающего набора.

После обучения модели используется ее для прогнозирования семантики (категории) для всех остальных облаков точек последовательности. После завершения этапа классификации выполняется этап кластеризации, чтобы найти отдельные листья или стебель как уникальные экземпляры. Кластеризация выполнена с использованием алгоритма пространственной кластеризации на основе плотности. Он использует x, y, z координаты точек для получения начальной сегментации, которая затем уточняется отбрасыванием небольших кластеров и отнесением каждой отброшенной точки к одному из оставшихся кластеров на основе k -подход ближайшего соседа.

На этом этапе каждая точка в облаке точек назначается органу, а именно стеблю или одному экземпляру листа. Затем мы изучаем ключевые точки для каждого органа, используя самоорганизующиеся карты. Эти ключевые точки будут образовывать узлы каркасной структуры. Самоорганизующиеся карты — это неконтролируемые нейронные сети, использующие концепцию конкурентного обучения вместо обратного распространения. Они принимают в качестве входных данных сетку, которая организует себя для захвата топологии входных данных. Учитывая входную сетку g и входной набор точек p самоорганизующаяся карта определяет полностью связанный слой между g и p . Эта сеть учится преобразованию сетки g точки в порядке кластеризации данных p эффективно. Процесс обучения состоит из двух чередующихся этапов до конвергенции. Во-первых, выигрышная единица вычисляется как:

$$x = \underset{p \in p}{argmin} ||p - w_i|| \quad (1)$$

где p — случайно выбранный образец, p а w_i - вектор веса, наиболее похожий на x , также называемый лучшей единицей

соответствия. Второй шаг состоит из обновления весов каждой единицы в соответствии с:

$$w_n = w_n + \eta \beta(i)(x - w_i) \quad (2)$$

где η — скорость обучения и $\beta(i)$ функция, которая взвешивает расстояние между единицей n и наилучшей подходящей единицей. В нашем случае сетка для каждого органа представляет собой $n \times 1$ цепочка 3D точек, которые будут образовывать узлы вдоль скелета для этого органа. Длина цепи n пропорциональна размеру органа, так что ожидается, что ключевые точки будут иметь минимальное расстояние между ними 1 см. Таким образом, можно получить скелетообразную структуру для каждого растения временной последовательности облаков точек растений. На рис. 1 визуализируется сегментация органов, а также структуры скелета, извлеченные из входного облака точек \mathcal{P} для двух выборочных сканирований нашего набора данных.




Рис.1. Извлечение скелетной структуры для использования семантики растения.

1.3 Оценка соответствий скелета

Прежде чем данные от любых 3D-объектов могут быть выровнены, необходимо установить ассоциации данных между показаниями датчиков, то есть оценить, какая часть облака ρ_1 соответствует каким частям облака ρ_2 . Установление этой ассоциации данных особенно сложно для объектов, которые меняют свой внешний вид, и автоматические процессы, вероятно, будут содержать выбросы ассоциации данных, что повлияет на последующее выравнивание. Для регистрации временно разделенных сканов растений мы предлагаем получать эти ассоциации данных путем сопоставления соответствующих структур скелета, а не работать непосредственно с необработанными облаками точек.

На этом этапе ассоциации данных мы оцениваем соответствия между двумя скелетами, используя их геометрическую структуру и семантику, которые вычисляются с использованием подхода, описанного в предыдущем разделе. Поскольку структура скелета и семантика оцениваются по измерениям датчиков, он может страдать от нескольких недостатков. Чтобы справиться с этими несовершенствами отдельных скелетов и несоответствиями между ними, используется вероятностный подход к связыванию частей скелета в отличие от подходов сопоставления графиков, которые обычно плохо переносят такие ошибки. Поэтому мы формулируем задачу поиска соответствий между парой скелетов (S_1, S_2) , используя формулировку скрытой марковской модели [3]. Модель СММ обеспечивает гибкость для кодирования различных сигналов, определения ограничений для соответствий, а также включения предварительной информации о структуре скелета. Это позволяет отслеживать несколько кандидатов на соответствие и выбирать наилучшие соответствия между парой скелетов.

Неизвестные или скрытые состояния модели СММ представляют все потенциальные соответствия между узлами двух скелетов. Кроме того, также добавляется в СММ так называемое “не согласованное состояние” для каждого узла, чтобы учесть ситуации, в которых узел может вообще не иметь соответствий. Это происходит, например, когда узлы принадлежат новым органам, которых раньше не было, или когда новые узлы появляются на скелете кривой из-за роста растения. Как требуется в формулировке СММ, нужно определить стоимость выбросов Z и стоимость перехода Γ . Стоимость выбросов Z описывает затраты для данного скрытого состояния (соответствия) на производство определенного наблюдения. В этом случае наблюдения представляют собой последовательность узлов первого скелета S_1 , расположенных, начиная с узла у основания стебля. Определим эту стоимость для соответствия $c_{ij} \in C_{12}$ между узлом $n_i S_1$ и узлом $n_j S_2$ следующим образом:

$$Z(c_{ij}) = w_d |\deg(n_i) - \deg(n_j)| + w_e \|x_i - x_j\| + w_{sem} \rho_{sem}(\mathcal{L}(n_i), \mathcal{L}(n_j)) \quad (3)$$

где первый член дает абсолютную разницу (обозначаемую $|\cdot|$) между степенями соответствующих узлов, где $\deg(n)$ - число ребер, падающих на узел. Второй член относится к евклидову расстоянию (обозначаемому $\|\cdot\|$) между ними с x_i, x_j - трехмерные местоположения узлов n_i, n_j соответственно. Конечный член ρ_{sem} равен единице в том случае, если семантика соответствующих узлов $\mathcal{L}(n_i), \mathcal{L}(n_j)$ не одинакова в противном случае он равен нулю. Идея объединения этих трех терминов состоит в том, чтобы захватить геометрические аспекты, то есть различие топологии, пространственное расстояние между узлами и семантику сопоставляемых узлов скелета. Эта совокупная стоимость будет

меньше для соответствий между узлами, которые имеют сходную топологию, расположены близко друг к другу и имеют одинаковую семантическую метку. Взвешиваются все три термина, используя w_d, w_e и w_{sem} масштабировать меры таким образом, чтобы они находились в аналогичном диапазоне. Для всех экспериментов мы установили $w_d = 1, w_e = 10$ и $w_{sem} = 1$.

Стоимость перехода Γ описывает стоимость перехода из одного скрытого состояния c_{ij} в другое c_{kh} . Это можно рассматривать как стоимость, связанную с тем, что c_{kh} является действительным совпадением, учитывая, что c_{ij} также является действительным совпадением. Определяется эту стоимость как:

$$\Gamma(c_{ij}, c_{kh}) = |d_g(n_i, n_k) - d_g(n_j, n_h)| + w_{nbr} |n_{br}(n_i, n_k) - n_{br}(n_j, n_h)| + \rho_{dir}((x_i - x_j), (x_k - x_h)) \quad (4)$$

где первый член вычисляет разницу геодезических расстояний d_g между узлами, участвующими в двух парах соответствий вдоль их соответствующих скелетов. Это означает, что пара соответствий (c_{ij}, c_{kh}) , имеющих равные геодезические длины $d_g(n_i, n_k)$ вдоль S_1 и $d_g(n_j, n_h)$ будут иметь меньшую стоимость, чем те, которые имеют значительно различную длину вдоль скелета. Второй член фиксирует разницу в количестве ветвей n_{br} , то есть узлов со степенью больше 2, по пути на скелете. Масса w_{nbr} автоматически устанавливается как максимальное геодезическое расстояние между всеми узловыми парами первого скелета. Конечный член ρ_{dir} — функция, штрафующая пары соответствий (c_{ij}, c_{kh}) с большими затратами, если направления, определяемые $(x_i - x_j)$ и $(x_k - x_h)$, противоположны, т. е. угол между ними больше $\frac{\pi}{2}$. Устанавливается штрафная стоимость как максимальное геодезическое расстояние между любыми двумя узлами на S_1 .

Как только определены затраты на эмиссию и переход, мы вычисляем соответствия между скелетами, выполняя вывод на СММ. Результатом является наиболее вероятная последовательность скрытых переменных, т. е. набор соответствий между S_1 и S_2 . Этот вывод выполняется с использованием алгоритма Витерби [2]. В случае, если узел имеет более одного соответствия, выбирается соответствие с меньшим евклидовым расстоянием, чтобы обеспечить взаимно однозначное соответствие. В качестве иллюстрации на рис. 2 слева показана примерная пара скелетов, для которой мы хотим оценить соответствия c_{12} . Справа изображен СММ для пары примеров, где красный путь указывает на набор соответствий, оцененных алгоритмом Витерби. Модель СММ показывает только подмножество связей между скрытыми состояниями, где на практике каждое состояние связано с каждым другим состоянием.

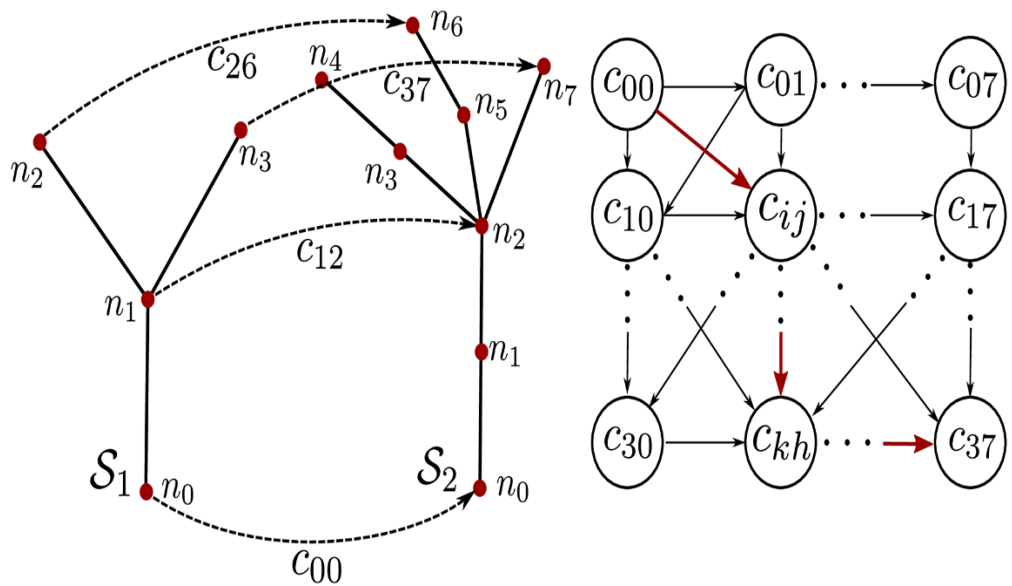


Рис.2. Примерная пара скелетов и СММ для этой пары.

1.4 Вычисление параметров деформации скелета

На этом этапе вычисляются параметры регистрации между S_1 и S_2 с учетом набора соответствий C_{12} . При регистрации временно разделенных сканов растений необходимо учитывать рост растений, который проявляется в виде изменения формы и топологии растения. Поэтому для фиксации этих изменений необходимо отказаться от обычного предположения о жесткости, часто используемого при регистрации облаков точек. Цель — зафиксировать нежесткие изменения путем вычисления наборов параметров деформации между скелетными частями соответствующих сканов растений. Оцениваются эти параметры деформации с помощью нелинейной процедуры оптимизации наименьших квадратов на основе соответствий, полученных из процедуры, описанной в предыдущем разделе.

Для моделирования деформаций между сканированиями растений прикрепляется аффинное преобразование T_i к каждому узлу n_i скелета S_1 , что показано на рис.4. Интуиция, лежащая в основе такой модели, заключается в том, что скелет может деформироваться по-разному в разных местах вдоль скелета. Моделируя деформации с помощью 3D-аффинного преобразования с 12 неизвестными параметрами на узел, можно фиксировать рост, а также изгиб растения с помощью параметров масштабирования, сдвига и вращения.

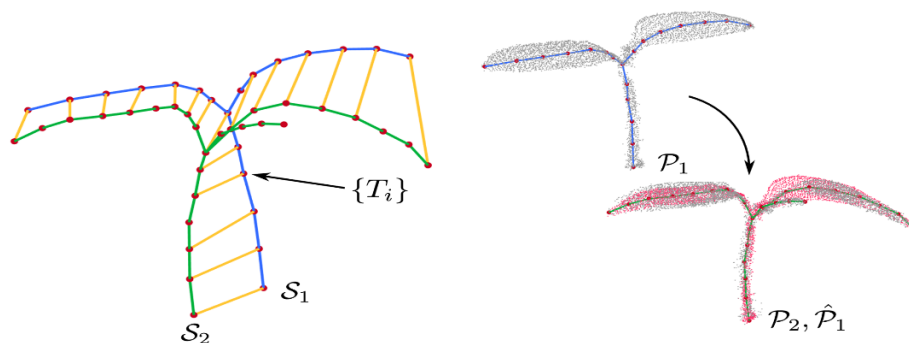


Рис.3. Регистрация пары скелетов с оценки параметров деформации и перенос результатов деформации на все облако точек.

Определим целевую функцию задачи оптимизации как комбинацию трех энергетических членов. Первый член $E_{corresp}$ определяется как:

$$E_{corresp} = \sum_{c_y \in C_{12}} ||T_i x_i - y_i|| \quad (5)$$

где x_i и y_j — позиции узлов, заданные парой соответствий c_{ij} , полученной с использованием процедуры, описанной в предыдущем разделе. Этот энергетический член фиксирует расстояние между соответствующими узлами в S_1 и S_2 для оценки аффинного преобразования T_i . Целью процедуры оптимизации будет выбор такого преобразования T_i , присоединенного к каждому узлу n_i , которое делает общую ошибку в уравнении (5) как можно меньшей.

Второй энергетический член E_{rot} фиксирует, насколько близко оцененное аффинное преобразование к чистому вращению, и определяет гладкость деформации. Определим E_{rot} как:

$$E_{rot} = \sum_{\substack{j=1 \\ j=mod(i+1,3)}}^3 (c_i c_j)^2 + \sum_{i=1}^3 (c_i c_j - 1)^2 \quad (6)$$

где c_i — столбцы вращательной части аффинного преобразования, то есть первые три строки и столбцы T_i . Первый член в E_{rot} в уравнении (6) измеряет отклонение пары столбцов от ортогональности друг другу, а второй член измеряет отклонение каждого столбца от единицы длины. E_{rot} оцененные аффинные параметры T_i быть как можно ближе к истинному вращению. Этот энергетический термин контролирует эффект сдвига и приводит к естественным деформациям.

Мы также определяем член регуляризации E_{reg} как:

$$E_{reg} = \sum_{j \in N(i)} \text{norm } F (T_i^{-1} T_j - 1) \quad (7)$$

где T_i, T_j — преобразования, соответствующие узлам n_i, n_j такие, что j — сосед $N(i)$ вдоль S_1 , а $\text{norm } F$ — норма Фробениуса после выполнения однородной нормализации вовлеченных матриц. E_{reg} — регуляризующий термин, заставляющий параметры трансформации соседних узлов быть сходными. Это приводит к плавной деформации вдоль скелета и достигает тех же результатов, что и максимально жесткое ограничение. Член регуляризации также необходим для ограничения узлов, не имеющих соответствий. Наконец, совокупная энергия E_{total} получается как взвешенная комбинация всех трех энергий в виде:

$$E_{total} = w_{corresp} E_{corresp} + w_{rot} E_{rot} + w_{reg} E_{reg} \quad (8)$$

Весы $w_{corresp} = 100, w_{rot} = 10$ и $w_{reg} = 1$ используются во всех описанных здесь примерах. Они были выбраны таким образом, чтобы стоимость, обусловленная каждой составляющей потерь, находилась в одном и том же порядке величины. Для решения неограниченной нелинейной задачи наименьших квадратов использован алгоритм Гаусса-Ньютона. Мы используем робастное ядро Коши [3] для остатков ошибок, принадлежащих $E_{corresp}$ так как это предотвращает некорректное влияние соответствий на процесс оптимизации. Робастное ядро автоматически нивелирует потенциально неправильные соответствия, имеющие большие невязки. Подход связан с формулировкой Самнера и др [5] для оценки параметров деформации поверхностей, параметризованных в виде треугольных сеток. В нашем случае мы адаптируем энергетические члены, чтобы отразить ограничения, действительные для деформации между скелетами кривых, а не поверхностями. Кроме того, подход Самнера и др. [5] не способна

полностью ограничить узлы, имеющие степень меньше 3, но необходима для регистрации кривых скелетов.

1.5 Деформация облака точек

Традиционные подходы к регистрации облаков точек предполагают жесткие объекты. В этом случае выравнивание приводит к выполнению преобразования 6 степеней свободы, состоящего из вращений и переводов. Однако в нашем случае это существенно отличается. Для получения конечного зарегистрированного облака точек ρ_1 для растущего растения необходимо применить параметры деформации, оцененные для узлов скелета, ко всем 3D точкам сканирования. Это означает, что отдельные точки данных будут подвергнуты индивидуальному аффинному преобразованию для получения выровненного облака.

Для каждой точки $p \in \rho_1$ получаем деформированную точку \dot{p} как взвешенную сумму аффинных преобразований, соответствующих двум ближайшим к точке p узлам в виде:

$$\dot{p} = \sum_{k \in N(p)} \alpha_k T_k p \quad (9)$$

где k — индекс ближайшего узла $N(p)$ и α_k вычисляется по проекции точки p на ребро скелета, определяемой ближайшими узлами. Пусть p_e — проекция точки p на ребро e . Тогда вес задается формулой:

$$x_k = 1 - \frac{\|p - e\|}{\|e\|} \quad (10)$$

1.6 Итерационная нежесткая процедура регистрации

При помощи предыдущих разделов нужно сформулировать итерационный подход к регистрации пары облаков точек P_1, P_2 , как описано в Алг. 1. Подобно популярному подходу ICP [8], мы чередуем шаги оценки соответствия и шаги регистрации с учетом соответствий. Начинается с вычисления сегментации экземпляра органного уровня и структуры скелета с семантической информацией (строки 3-6 Алг. 1). Затем запускается итерационную процедуру, которая чередуется с оценкой соответствий C_{12} (строка 9) и параметры регистрации, т. е. 3D аффинные преобразования, прикрепленные к каждому узлу (строка 10). Повторяя эти шаги несколько раз, можно получить новые соответствия, которые могли бы не быть захвачены из-за большого расстояния между скелетами при их начальной конфигурации. Далее производится выход из итерационной схемы, когда нет изменения в оценочном наборе соответствий C_{12}^t . После вычисления параметров регистрации T_{12} между узлами скелетов S_1 и S_2 применяются эти параметры ко всему облаку точек P_1 , в результате чего получается зарегистрированное облако точек \hat{P}_1 (строка 11)

1.7 Облака точек интерполяции растений

В дополнение к регистрации сканов растений, записанных в разное время, также нужно бы интерполировать, как растение может быть деформировано в промежуточное время между фактическими временами сбора. Это может позволить увеличить время между записями и провести дальнейший анализ интерполированных облаков точек. Вычисляется деформированное облако точек путем интерполяции параметров деформации T , оцененных между двумя зарегистрированными сканированиями. Для получения гладкой

интерполяции сначала разлагается оцененное аффинное преобразование T на масштабное сдвиговое преобразование T_s , чистое вращение T_R , и чистый перевод T_t с использованием подхода полярной декомпозиции, описанного Шумейком [4] и заданного:

$$T = T_s T_R T_t \quad (11)$$

Затем линейно интерполируются T_s и T_t , чтобы получить преобразование в момент времени t . Для интерполяции T_R используется сферическая линейная интерполяция, описанная Шумейком.

1.8 Вычисление фенотипических признаков

В данной работе вычисляются различные фенотипические признаки как для экземпляров стебля, так и для листьев. В частности, для класса стеблей вычисляются диаметр и длина стеблей, а для класса листьев - длина и площадь листьев. Мы выбираем эти признаки в качестве примеров, и другие геометрические признаки, которые используют площадь или форму органов, также могут быть вычислены и отслежены во времени[1].

Длина стебля и листа может быть легко вычислена из геометрической информации семантического скелета: длина стебля/листа - это просто сумма длин ребер всех узлов конкретного экземпляра.

Для вычисления диаметра стебля s_d сначала назначается каждая точка в облаке точек, классифицируемом как стебель, ближайшему узлу на скелете. Затем вычисляется главная ось распределения данных в соседней области выбранного узла с использованием стандартного подхода сингулярной декомпозиции (SVD). Затем можно вычислить диаметр стебля относительно главной оси рассматриваемой окрестности. Диаметр стебля s_d получается следующим образом:

$$s_d = 2 \sum_n \frac{1}{k_n} \sum_{k_n} ||p_k - \pi_l(p_k)|| \quad (12)$$

где n — число узлов стебля, k_n — число точек в облаке точек, назначенных n -му узлу, а $\pi_l(\cdot)$ — функция, проецирующая точку на главную ось.

Можно вычислить площадь листа l_a , используя SVD для оценки главной плоскости A точек, связанных с каждым узлом. Это дает нам площадь листа l_a в виде:

$$l_a = \sum_m \text{hull}(\pi_A(p_k)) \quad (13)$$

где $\text{hull}(\cdot)$ представляет собой площадь выпуклой оболочки и $\pi_A(\cdot)$ проекцию всех точек p_n , связанных с n -м узлом, на главную плоскость A . Итоговая сумма берется по всем m узлам листа.

1.9 Описание набора данных

Подход оценивается на данных 3D-облаков точек временных рядов трех образцов растений кукурузы (*Zea mays*) и томатов (*Solanum lycopersicum*). Сканы регистрировались с помощью роботизированной руки, оснащенной высокоточным лазерным сканером. Набор данных регистрировался ежедневно в течение 10 дней. Растения сканировались таким образом, чтобы по возможности минимизировать самоокклюзии. Данные облака точек проходят этап предварительной обработки, на котором удаляются все точки, которые не принадлежат растению, например точки, принадлежащие почве и горшку. Наборы данных охватывают значительный рост растений, начиная с 2 семядолей (т. е. семенных листьев) в начале до примерно 8 листочков (2 семядоли + 2 листа) для растений томата и от 1 до 4 листьев для растений кукурузы. Растения претерпевают значительный рост листьев и стеблей и включают несколько событий ветвления до конца периода

сбора данных. Высота растений томата достигает 150 мм, а растения кукурузы-более 400 мм.

1.10 Семантическая классификация облаков точек растений

В первом эксперименте оценивается эффективность подхода для семантической классификации уровня органа. Система классификации была обучена на двух случайно выбранных облаках точек из каждого набора данных. Все остальные облака точек в последовательности используются в качестве тестовых наборов данных. Информация о наземной истинности как для обучающих, так и для тестовых наборов была сгенерирована вручную пользователями-людьми. Демонстрируются качественные результаты, вычисленные подходом, визуализируя семантические экземпляры для некоторых облаков точек из двух наборов данных на рис. 4.




Рис. 4. Семантическая классификация облаков точек кукурузы (сверху) и томата (снизу).

Каждый экземпляр стебля и листа визуализируется различным цветом. Можно визуально осмотреть экземпляры стебля и листьев на протяжении всей временной последовательности и увидеть, что классификация успешна для экземпляров, несмотря на изменение их размера и формы с течением времени. Цвета одних и тех же

экземпляров листьев не сохраняются во временной последовательности, так как ассоциации данных между ними на данном этапе не вычислены.

Также проводится количественная оценка эффективности классификации классификационного подхода путем вычисления стандартных показателей, таких как точность $p = \frac{tp}{tp+fp}$ (см. Прил. таблица 1), отзыв $r = \frac{tp}{tp+fn}$ (см. Прил. таблица 2) и пересечение над объединением (IoU) $IoU = \frac{tp}{tp+fp+fn}$ (см. Прил. таблица 3), для наборов данных растений кукурузы и томатов. Для каждой метрики демонстрируются минимальные и максимальные значения по набору данных, а также стандартное отклонение. В приведенных выше определениях tp означает true positive, fp -false positive и fn для ложноотрицательных. Во всех таблицах SVM отвечает за класс стебля и листа, в то время как instance относится к неконтролируемой кластеризации отдельных листьев. Получается более 90% точности и отзыва для точки листа в обоих наборах данных, тогда как для точек стебля они составляют около 85%. Что касается экземпляров листьев, то оба показателя составляют около 90% [1].

Несмотря на эти точные результаты, стоит отметить, что способность SVM классифицировать точки стебля ниже в наборе данных кукурузы, чем в наборе данных томатов. Это связано с более плавным переходом между стеблем и листьями у растений кукурузы. Напротив, производительность кластеризации выше на наборе данных кукурузы. Это поведение можно объяснить, посмотрев, как развиваются листья у двух видов. В то время как для растений кукурузы существует четкое разделение между отдельными листьями, это разделение не так ясно для листьев растений томата. Для справки показаны метки наземной истинности

для двух примеров растений, используемых при оценке семантической классификации в Рис.5.



Рис. 5. Пример меток наземной истинности, используемых при оценке семантической классификации облаков точек кукурузы (слева) и томата (справа).

1.11 4D регистрация облаков точек растений

Во втором эксперименте демонстрируется, что подход успешно регистрирует данные облака точек временных рядов для двух типов растений. Используется одни и те же веса для нашей процедуры регистрации, как описано в разделе "Методы" для всех пар сканирования (наборов данных томатов и кукурузы) на разных стадиях роста. Также выполнена количественная оценка точности регистрационного конвейера. Рис.6 иллюстрирует результаты процедуры регистрации для двух примеров пар сканирования из наборов данных кукурузы (вверху) и томатов (внизу). Для обоих примеров показаны входные облака точек (P_1, P_2) вместе с соответствующими им скелетами. Оцениваемые в процессе регистрации соответствия изображаются пунктирными линиями, соединяющими узлы скелетной пары. Подход позволил надежно найти соответствия, несмотря на рост и изменение топологии. Визуализируется конечное зарегистрированное облако точек \hat{P}_1 (розовым цветом) путем деформации облака точек P_1 использование параметров деформации, оцененных подходом, и наложение их на целевое облако точек P_2 (серым цветом) и обратите внимание, что он хорошо перекрывается,

указывая на то, что результаты регистрации являются разумными. Большинство зарегистрированных точек \hat{P}_1 (розовым цветом) перекрывает целевое облако P_2 точек. Однако мы замечаем, что ошибки обычно высоки по отношению к внешним участкам листьев, которые находятся дальше от кривой скелета. Этот эффект следует ожидать, поскольку скелетные кривые плохо захватывают эту область.




Рис. 6. 4D-регистрация пары облаков точек, сканированных в последовательные дни для растений кукурузы (сверху) и томата (снизу).

Кроме того, количественно оценивается точность регистрационного конвейера, регистрируя все последовательные сканы двух наборов данных. Во-первых, вычисляется точность процедуры сопоставления скелетов, вычисляя процент правильно оцененных соответствий. Мы определяем правильные соответствия как те, которые принадлежат одному и тому же органу (т. е. одному и тому же листу или стеблю) в паре скелета, поскольку нет уникального способа определить правильное соответствие из-за роста растения. Вручную маркируются различные органы растения уникальным идентификатором, чтобы обеспечить основную истину для вычисления этой метрики. Для наших наборов данных томатов получается в среднем 95% правильных соответствий между

последовательными парами скелетов, причем большинство пар имеют все соответствия, оцененные правильно. Для набора данных кукурузы получается 100% соответствий между последовательными днями правильно. Аналогичным образом мы также оценили точность оценки соответствия между парами скелетов с интервалом 2 и 3 дня друг от друга. Для набора данных томата мы снова получаем в среднем 95% соответствий при сканировании с интервалом в 2 дня, тогда как при сканировании с интервалом в 3 дня этот показатель падает до 88%. Опять же для набора данных кукурузы получается все соответствия правильно как со скелетами, взятыми с интервалом 2, так и с интервалом 3 дня. Более высокая точность для растений кукурузы, вероятно, обусловлена более простой формой растения по сравнению с растениями томата.

Во-вторых, оценивается точность оцененных параметров регистрации путем вычисления ошибки между деформированным облаком точек источника \hat{P}_1 и облаком точек цели P_2 . Определим эту ошибку регистрации e_{reg} следующим образом:

$$e_{reg} = \frac{1}{|\hat{P}_1|} \sum_{\substack{i=1 \\ j \in N(i)}}^{|\hat{P}_1|} \|p_1^i - p_2^i\| \quad (14)$$

Где p_2^i — ближайшая точка к p_1^i и $|\hat{P}_1|$ — количество точек $|\hat{P}_1|$. Для нашего набора данных мы получаем среднюю ошибку 3 мм при стандартном отклонении 2,3 мм и максимальную ошибку 13 мм для последовательных сканирований, что свидетельствует о точности результатов регистрации.

Поскольку эта мера регистрации может быть восприимчива к некоторым вырожденным случаям, крайним случаем является $p_i \in P_1$ деформация всех точек в одну точку с $p_j \in P_2$ нулевой ошибкой регистрации. Поэтому используется информация экземпляра для

определения наличия таких вырожденных ситуаций. Вычисляется процент точек в $ПК_1$, деформированных к соответствующим экземплярам наземной истины в $ПК_2$. Это дает меру того, насколько хорошо экземпляры отображаются после применения параметров деформации. Получается средняя точность 97% для набора данных кукурузы и 89% для набора данных томатов с большинством ошибок, возникающих в местах слияния листьев со стеблем. Полученные результаты свидетельствуют о том, что параметры регистрации деформируют экземпляры должным образом и не приводят к вырожденным оценкам.

В качестве базового сравнения предполагается жесткое преобразование для всего облака точек между последовательными сканированиями и вычисляется преобразование с помощью стандартного подхода ICP. Средняя ошибка e_{reg} для данного эксперимента составляет 35 мм, а максимальная-166 мм. Большие ошибки при использовании жесткого предположения о трансформации обусловлены как ростом растений, так и в некоторых случаях полным отклонением процедуры ICP. Это указывает на то, что предположение о жесткой трансформации неадекватно и требуется нежесткая процедура регистрации для захвата роста и движения растения [1].

Визуализируется ошибка регистрации в виде тепловой карты для двух пар примеров облаков точек на рис.7. Тепловая карта проецируется на P_1 показать, насколько хорошо регистрируются различные части растения. Синие области на тепловой карте представляют меньшую ошибку регистрации, тогда как желтые области указывают на большие ошибки. Большая часть областей синего цвета указывает на успешную регистрацию, однако мы замечаем, что ошибки обычно высоки по отношению к внешним участкам листьев, которые находятся дальше от кривой

скелета. Этот эффект следует ожидать, поскольку скелетные кривые плохо захватывают эту область.




Рис. 7. Визуализация ошибки регистрации.

1.12 Временное отслеживание фенотипических признаков

В этом эксперименте мы показываем, что результаты пространственно-временной регистрации, вычисленные нашим подходом, позволяют вычислить несколько фенотипических признаков и отслеживать их во времени. Вычисляется площадь l_a и длину l_l для экземпляров листьев и диаметр s_d и длину s_l стебля для каждого облака точек во временной последовательности, как описано ранее, и связываем его во времени, используя ассоциации данных, оцененные подходом в процессе регистрации. Результаты отслеживания для трех образцов растений из наборов данных кукурузы и томатов визуализированы на рис. 8. Первые две колонки отслеживание площади листьев и длины листьев с течением времени. Различные оттенки синего и зеленого на этих участках представляют отдельные экземпляры листьев. Кроме того, мы также можем обнаружить определенные события, которые отмечают топологическое изменение структуры растения, такое как появление нового листа. Эти события могут быть распознаны по участкам площади листа или длины листа всякий раз, когда новая линия поднимается от нулевого уровня. Например, для первого растения в наборе данных кукурузы новый лист появляется на 2, 3 и 6 день. В крайнем правом столбце наблюдается что длина и диаметр стебля

для обоих наборов данных значительно увеличиваются за период сбора данных. Такая фенотипическая информация также может быть использована для вычисления шкалы ВВСН [6] растения, которая является шкалой стадии роста и предоставляет ценную информацию агрономам.

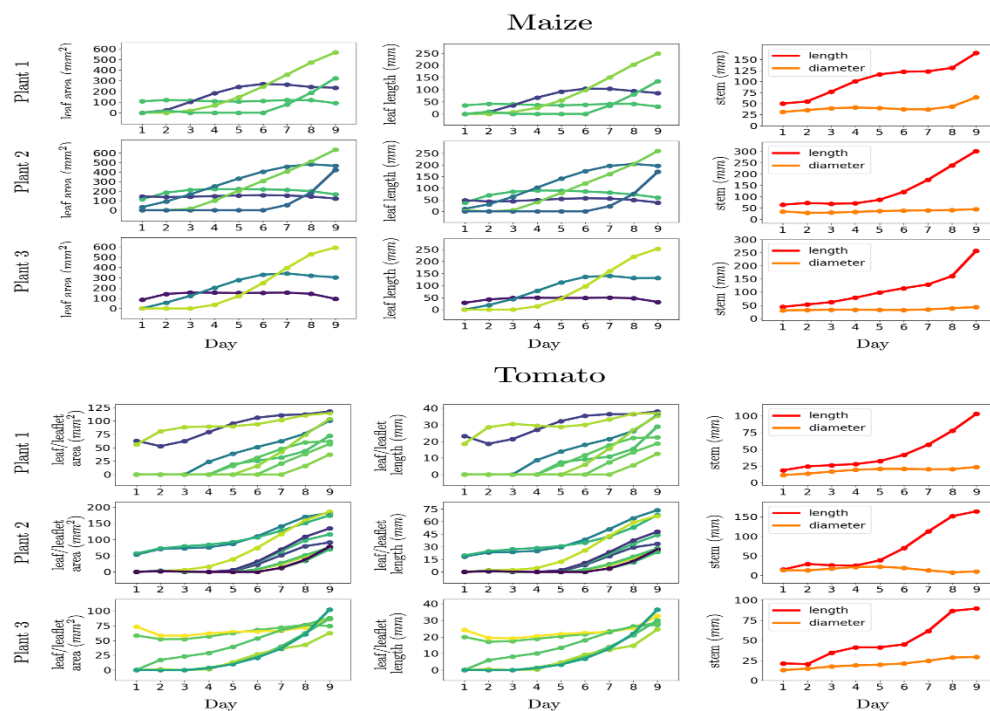


Рис. 9. Отслеживание фенотипических признаков по отдельным органам растения.

1.13 Временная интерполяция облаков точек растений

В последнем эксперименте продемонстрировано, что результаты регистрации могут быть использованы для интерполяции облаков точек в промежуточные моменты времени, т. е. между фактическими временами получения сканирований. Возможность интерполяции полезна для анализа свойств растений, даже когда фактические измерения недоступны. Это позволяет прогнозировать как движение, так и рост на промежуточных временных интервалах. Визуализируется интерполированное облако точек в трех временных экземплярах t_1^i, t_2^i и t_3^i между двумя сканированиями в верхней

части рис.9. Это позволяет анимировать покадровый вид растений. Розовые облака точек представляют собой интерполированные сканы и хорошо перекрываются с облаком точек (серым) в момент времени t , указывая на то, что интерполяция является разумной. Поскольку процедура интерполяции фактически не моделирует движение или рост растения, результат интерполяции может отличаться от фактического растения в этих случаях. Для оценки шага интерполяции используются сканы в день $t-1$ и день $t+1$, затем интерполируем облако точек в день t и сравниваем с фактическим облаком точек в день t . Вычисляется ошибка регистрации (как описано в (14)) и получаем среднее значение e_{reg} 4 мм со стандартным отклонением 1,9 мм. Также вычисляется процент точек P_{t-1} , зарегистрированных в соответствующих примерах наземной истины P_1 , аналогично мере в регистрационных экспериментах. Получается средняя точность 91% для набора данных кукурузы и 83%, предполагая, что интерполяция является разумным приближением реального роста растений.




Рис. 9. Интерполяция облаков точек на промежуточных временных интервалах.

2. Проверка работоспособности программной реализации метода

Программно-техническая реализация метода автоматического фенотипирования растения написана на языке программирования Python и использует несколько его библиотек:

NumPy — open-source библиотека, которая предоставляет общие математические и числовые операции в виде пре-скомпилированных, быстрых функций. Они объединяются в высокоуровневые пакеты.

Matplotlib — библиотека для визуализации данных двумерной (2D) графикой (3D графика также поддерживается).

SciKit-Learn — это свободно распространяемая библиотека для работы с методами машинного обучения. Она содержит реализации методов классификации, регрессии и кластеризации, а также нейронных сетей. SciKit предоставляет широкий набор инструментов для решения проблемы размерности данных, сравнения моделей машинного обучения и их производительности и для извлечения важных признаков.

MiniSom — минималистичная и основанная на Numpy реализация самоорганизующихся карт (SOM). SOM-это тип искусственной нейронной сети, способной преобразовывать сложные нелинейные статистические отношения между элементами данных высокой размерности в простые геометрические отношения на низкоразмерном дисплее. Minisom разработан, чтобы позволить исследователям легко строить поверх него и дать студентам возможность быстро понять его детали.

Dijkstra — реализация алгоритма кратчайших путей Дейкстры с одним источником. Если задан конечный узел, алгоритм

останавливается при достижении этого узла; в противном случае он продолжается до тех пор, пока не будут найдены пути от исходного узла ко всем другим узлам. Принимает необязательную функцию *cost* (или “weight”) , которая будет вызываться на каждой итерации. Также принимает дополнительную эвристическую функцию, которая используется для продвижения алгоритма к месту назначения, а не для распространения во всех направлениях. Использование такой эвристической функции преобразует Dijkstra в A* (и именно отсюда происходит название “Dijkstra”).

Open3D — библиотека с открытым исходным кодом, которая поддерживает быструю разработку программного обеспечения для работы с 3D-данными. Интерфейс Open3D предоставляет набор тщательно отобранных структур данных и алгоритмов как на C++ , так и на Python. Бэкэнд хорошо оптимизирован и настроен на распараллеливание.

Jupyter Notebook — оригинальное веб-приложение для создания и обмена вычислительными документами. Он предлагает простой, оптимизированный, ориентированный на документы опыт.

Jupyter Lab — новейшая интерактивная веб-среда разработки для ноутбуков, кода и данных. Его гибкий интерфейс позволяет пользователям настраивать и организовывать рабочие процессы в области науки о данных, научных вычислений, вычислительной журналистики и машинного обучения. Модульная конструкция предлагает расширения для расширения и обогащения функциональности.

Для запуска можно использовать Anaconda Navigator с предустановленными библиотеками, которые описаны выше или установить все тоже самое, но для Microsoft Visual Studio Code

По ссылке находящейся в статье об текущем методе автоматического фенотипирования нужно перейти на Github —

источник исходного кода проекта. В репозитории разработчиков указаны все компоненты для запуска (библиотеки), а также информация о файле для автоматической установки этих модулей через программную среду разработки. Не рекомендуется им пользоваться, так как могут возникнуть проблемы с версией этих библиотек. Лучше всего устанавливать вручную через консоль. Для запуска программы нужно было слегка изменить код для исправления ошибок (см. Прил.).

После запуска программа постепенно выдает результаты в виде отрисованных 3D-изображений.

Демонстрируется все это на примере кукурузы и томата. Рассмотрим процедуру сканирования одного из объектов (кукурузы). Начинается процедура с начальной облачной точки сканирования и семантической классификации органов растения (рис.10,11).




Рис.10. Начальная облачная точка сканирования.




Рис.11. Семантическая классификация органов растения

Далее происходит построение и регистрация структуры скелета растения(рис.12). При любом изменении формы растения и получением новых данных по этому событию модель при помощи облака точек перестраивается, добавляя или удаляя части тела скелета при сопоставлении разных данных полученные в начальный и текущий периоды жизни кукурузы(рис.13,14), что помогает как можно качественнее детализировать финальный результат(рис.15).




Рис.12. Отображение структуры скелета кукурузы.

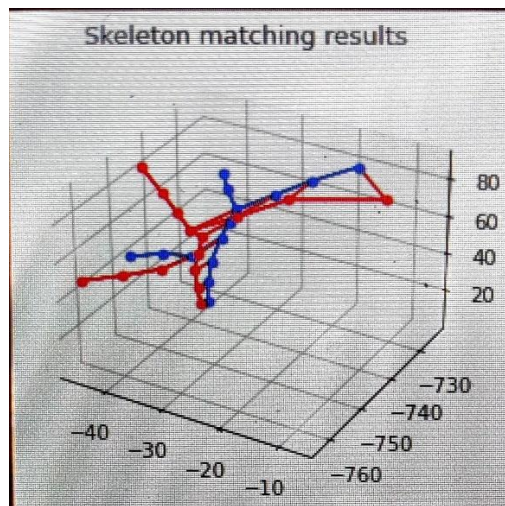


Рис.13. Сопоставление разных моделей данных о скелете.

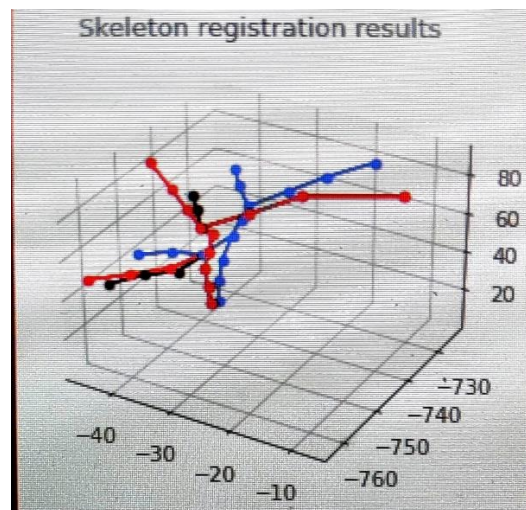


Рис.14. Результаты регистрации изменений скелета в модели.




Рис.15. Финальный результат.

Заключение

Цель и задачи работы являются полностью выполнены. При проверке работоспособности реализации метода и применимости результатов выяснилось, что исходный код, находящийся в открытом доступе, работает отлично и доказывает качественность выводимых результатов, о которых говорится в статье.

В данной работе представлен новый подход к пространственно-временной регистрации трехмерных облаков точек отдельных растений. Предлагаемый способ работает для необработанных сенсорных данных, полученных от датчика диапазона, такого как 3D-датчик или глубинная камера. Обработка данных датчиков происходит полностью автоматизированным способом без ручного вмешательства. Реализован и оценен подход на наборах данных растений томатов и кукурузы, представляющих сложные ситуации, и поддержали все утверждения, сделанные в этой статье. Эксперименты показывают, что этот подход к регистрации может быть использован в качестве основы для временного отслеживания признаков растений и способствовать автоматизированному фенотипированию.

Список использованных источников

1. Регистрация пространственно-временных облаков точек растений для фенотипирования / Нивея Чебролу, Федерико Магистри, Томас Ли, Сирилл Стачнисс // инклюзивное сообщество журналов PLOS ONE — URL: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0247243#ack> (Дата обращения: 21.12.2021) — Режим доступа: открытый доступ.
2. Границы ошибок сверточных кодов и асимптотически оптимальный алгоритм декодирования / Витерби А. // IEEE Trans on Information Theory. 1967;13(2):260-269. — URL: <http://www.essrl.wustl.edu/~jao/itrg/viterbi.pdf>. (Дата обращения: 25.12.2021) — Режим доступа: открытый доступ.
3. Любой ценой: сравнение робастных функций затрат для выбросов соответствия камеры / Мактавиш К., Барфут Т. Д. // Книга: Материалы Конф. по компьютерному и роботизированному зрению; 2015. С. 62-69. — URL: http://ncfrn.mcgill.ca/members/pubs/AtAllCosts_mactavish_cv15.pdf. (Дата обращения: 23.12.2021) — Режим доступа: открытый доступ.
4. Матричная анимация и полярная декомпозиция / Шумейк К., Дафф Т. // В кн.: Материалы Конф. по графическому интерфейсу. т. 92; 1992. с. 258-264. — URL: <https://research.cs.wisc.edu/graphics/Courses/838-s2002/Papers/polar-decomp.pdf>. (Дата обращения: 22.12.2021) — Режим доступа: открытый доступ.

5. Встроенная деформация для манипулирования формой / Самнер Р. В., Шмид Дж., Полли М.// ACM Trans on Graphics (TOG). 2007 — URL: <https://people.inf.ethz.ch/~sumnerb/research/embdef/Sumner2007EDF.pdf>. (Дата обращения: 22.12.2021) — Режим доступа: открытый доступ
6. Использование расширенной шкалы BBCH—general для описания стадий роста моно-и двудольных видов сорняков / Хесс М, Барралис Г, Блейхолдер Х, Бур Л, Эггерс Т, Хак Х и др. // Исследование сорняков. 1997;37(6):433-441. — URL: <https://onlinelibrary.wiley.com/doi/abs/10.1046/j.1365-3180.1997.d01-70.x> . (Дата обращения: 22.12.2021) — Режим доступа: открытый доступ

Приложение

Ссылка с исправленным кодом проекта:

https://github.com/Ragnarok7861/4d_plant_registration

Таблица 1

Dataset	Stem				Leaf				Instances			
	mean	min	max	std	mean	min	max	std	mean	min	max	std
Maize	86.3	74.5	99.6	8.6	95.5	93.6	99.4	2.2	94.4	91.9	99.6	2.7
Tomato	89.6	68.6	99.2	9.6	97.9	96.9	99.0	0.9	83.4	59.8	99.7	15.4

Таблица 2

Dataset	Stem				Leaf				Instances			
	mean	min	max	std	mean	min	max	std	mean	min	max	std
Maize	85.7	48.6	99.1	16.3	92.9	89.1	99.8	3.3	94.7	91.3	99.6	3.1
Tomato	92.2	60.6	99.4	11.4	96.5	74.0	99.6	8.3	78.2	66.6	99.4	11.2

Таблица 3

Dataset	Stem				Leaf				Instances			
	mean	min	max	std	mean	min	max	std	mean	min	max	std
Maize	80.0	47.8	94.6	12.7	94.6	88.9	97.4	2.5	94.0	91.0	97.6	2.3
Tomato	82.6	60.6	92.2	10.4	93.4	73.9	99.0	7.8	69.1	51.4	98.7	15.7